



بازیابی پیشرفته اطلاعات

نیم‌سال اول ۹۸-۹۹

مدرس: حمید بیگی

فاز اول پروژه (۸۵ نمره + ۱۵ نمره امتیازی)

زمان تحویل: ۱ آذر ماه

هدف از فاز اول پروژه پیاده‌سازی یک سیستم بازیابی اطلاعات است. فاز اول پروژه از ۵ بخش تشکیل شده است و دو مجموعه داده نیز در اختیار شما قرار دارد. مجموعه‌ی اول که به زبان انگلیسی است، شامل چندین مقاله خبری است که توسط موتور جستجوی آکادمیک ComeToMyHead جمع‌آوری شده‌اند. توجه کنید که این مجموعه داده شامل دو ستون عنوان و متن خبر است. مجموعه داده دوم به زبان فارسی است و بخشی از پیکره‌ی ویکی‌پدیای فارسی شامل چندین صفحه ویکی‌پدیا به فرمت xml است. توجه نمایید که تمامی صفحات در یک فایل xml قرار دارند و شما باید ابتدا با بررسی فایل و فهمیدن الگوی ذخیره‌سازی، هر صفحه را به صورت جدا استخراج نمایید زیرا هر صفحه یک مستند (document) مجزا است.

بخش اول به پیش‌پردازش متنی داده‌ها می‌پردازد که شامل یکسان‌سازی متن، جداسازی لغات، حذف لغات پرتکرار و ... است. بخش دوم نمایه‌سازی است. در بخش سوم نیز باید روی این نمایه فشرده‌سازی صورت بگیرد. در ادامه، قسمت جستجو و بازیابی سیستم قرار دارد که در بخش چهارم پرسن و ورودی کاربر را باید تصحیح کرده و در بخش پنجم از نمایه‌های پیاده‌سازی شده برای جست‌وجو استفاده می‌شود.

بخش ۱. پیش‌پردازش اولیه (۲۵ نمره)

در این بخش از پروژه ابتدا باید مجموعه فایل‌هایی که در اختیارتان قرار گرفته است را بخوانید سپس به ترتیب مراحل پیش‌پردازش متنی که در ادامه آمده است را روی آن‌ها اعمال کنید. برای اعمال پیش‌رو می‌توانید از کتابخانه‌های آماده استفاده کنید. برای زبان پایتون کتابخانه هضم و جاوا JHazzm پیشنهاد می‌شود. برای یکسان‌سازی متون انگلیسی می‌توانید از کتابخانه NLTK استفاده کنید.

۱. **نرمال‌سازی متنی (normalization):** برای یکسان‌سازی متون می‌توانید از توابع کتابخانه‌های معرفی شده استفاده کنید. اما در صورتی که می‌خواهید خودتان پیاده‌سازی کنید باید پیاده‌سازی‌تان شامل برگرداندن لغات به ریشه، case folding (برای یکسان‌سازی متون انگلیسی) و بقیه مواردی که در درس بیان شده است باشد.

۲. **جداسازی (tokenization):** برای این کار می‌توانید از توابع کتابخانه‌های معرفی شده استفاده کنید.

۳. **حذف علائم نگارشی:** هر کدام از مجموعه متن‌ها یک سری علائم نگارشی مثل نقطه، ویرگول و ... دارند که آن‌ها را باید حذف کنید.

۴. **یافتن و حذف لغات پرتکرار (stopwords):** در این بخش، حذف درصد معقولی از لغات پرتکرار مورد نظر است. برای این منظور لازم است تا همه متن را پردازش کنید و نسبت به حجم متن، کلماتی که پرتکرار هستند را نمایش دهید. این نسبت را طوری در نظر بگیرید که کلمات پرتکرار به دست آمده، تا حد خوبی منطقی و کافی باشند.

۵. **بازگرداندن کلمات به ریشه (stemming):** در نهایت افعال، اسامی و ... را به حالت ساده و پایه ای خود برگردانید.

بارم‌بندی

۱. گرفتن متن از کاربر و نمایش لغات آن بعد از پیش‌پردازش متنی (۱۵ نمره)

۲. نمایش لغات پرتکرار (از متون در اختیار قرار گرفته) (۱۰ نمره)

بخش ۲. نمایه‌سازی (۲۵ نمره)

در این بخش پیاده‌سازی نمایه جایگاهی (Positional) و نمایه Bigram مطلوب است. برای نمایه جایگاهی باید به ازای هر لغت، لیستی از اسناد شامل آن لغت و جایگاه (ها) هر لغت در آن سند را داشته باشید و برای نمایه Bigram نیز ترکیب‌های دو حرفی تمامی کلمات موجود در لغت‌نامه که این ترکیب در آنها موجود است را ذخیره کنید. این نمایه برای قسمت اصلاح پرسمان مورد استفاده قرار خواهد گرفت. نمایه شما باید پویا باشد یعنی با حذف سند از نمایه نیز حذف شده و با اضافه کردن سند در طول اجرای برنامه به نمایه اضافه شود. همچنین بعد از نمایه‌سازی باید قادر باشید نمایه را در فایلی ذخیره کرده و از آن بخوانید.

بارم‌بندی

۱. نمایه‌سازی از روی پوشه‌های در اختیار قرار داده شده (۱۵ نمره)

۲. نمایش posting list کلمه ورودی توسط کاربر (۵ نمره)

۳. نمایش جایگاه کلمه وارد شده توسط کاربر در هر سند (۵ نمره)

بخش ۳. فشرده‌سازی نمایه‌ها (۱۵ نمره)

در این بخش هدف فشرده‌سازی نمایه‌های ساخته‌شده به دو روش variable byte و gamma code است. (برای ذخیره‌سازی در فایل و بخش‌های بعدی می‌توانید فقط یکی از این دو روش را ادامه دهید.)

بارم‌بندی

۱. نمایش میزان حافظه اشغال شده قبل و بعد از اعمال variable byte (۵ نمره)

۲. نمایش میزان حافظه اشغال شده قبل و بعد از اعمال gamma code. (۵ نمره)

۳. ذخیره‌سازی نمایه‌ها در فایل و بارگذاری از آن (۵ نمره)

بخش ۴. اصلاح پرسمان (۱۰ نمره)

در صورتی که پرسمان ورودی دارای غلط املایی باشد، یا به عبارتی لغت (هایی) از آن در لغت‌نامه موجود نباشد، لازم است که با جستجوی لغت‌های احتمالی و انتخاب بهترین لغت به ادامه‌ی جستجو با پرسمان اصلاح شده پرداخته شود. برای اینکار ابتدا باید به وسیله‌ی روش bigram و معیار jaccard نزدیک‌ترین لغات به لغت با غلط املایی را پیدا کنید. سپس بهترین لغت از میان آن‌ها را با استفاده از معیار edit distance بیابید.

بارم‌بندی

۱. نمایش پرسمان اصلاح شده (۱۰ نمره)

بخش ۵. جستجو و بازیابی اسناد (۱۰ نمره + ۱۵ نمره امتیازی)

در این بخش دو روش جستجو باید به صورتی که در ادامه توضیح داده شده است، پیاده‌سازی شوند. البته توجه نمایید که روش دوم جستجو امتیازی است.

۱. جستجوی ترتیب‌دار در فضای برداری $tf-idf$ به روش $lnc-ltc$: در این روش جستجو بعد از دریافت پرسمان ورودی، باید لیستی از اسناد مرتبط به ترتیب امتیاز نمایش داده شود.

۲. جستجوی proximity با اندازه‌ی پنجره‌ی وارد شده در ورودی (امتیازی): در این روش جستجو ابتدا باید اسنادی که تمام کلمات پرسمان در یک بازه‌ی به اندازه‌ی پنجره‌ی داده شده، در آن سند وجود داشته باشند، پیدا شوند. سپس از بین آن‌ها به ترتیب امتیازشان براساس جستجوی ترتیب‌دار در فضای برداری $tf-idf$ به روش $lnc-ltc$ داک‌ها نمایش داده شوند.

توجه: برای هر دو نوع جستجو نمایش ۱۰ سند در صورت موجود بودن کافی می‌باشد. مجدداً توجه نمایید که روش دوم جستجو امتیازی است.

بارم‌بندی

۱. نمایش لیست اسناد مرتبط به ترتیب شباهت در جستجوی ترتیب‌دار در فضای برداری $tf-idf$ به روش $lnc-ltc$ (۱۰ نمره)

۲. نمایش لیست اسناد مطابق با پرسمان و اندازه پنجره ورودی در جستجوی proximity (۱۵ نمره امتیازی)

بخش ۶. نکات

۱. باید یک واسط کاربری برای تست موارد مختلف مشخص شده در قسمت بارم‌بندی هر بخش، برای تحویل حضوری وجود داشته باشد. واسط کاربری می‌تواند تحت کنسول پیاده سازی شود.

۲. امکان تغییر بارم‌بندی وجود دارد.